

メディア制作演習 (データ分析)

担当：大用庫智

2018年春学期開始

関西学院大学 総合政策学部

- データの中身

- 2ヶ月分のある商品Aの売上データを、売上個数、来店客数、価格、競合の価格、最高気温、陳列方法の6個の原因を集計

- 表: 2ヶ月分のある商品Aの売上データ

no	最高気温	陳列方法	価格	競合価格	売上個数	来店客数
1	27.8	B	160	168	82	579
2	27.8	A	160	168	57	602
3	28.4	A	175	180	46	501
...	.	.	.	.	.	.
61	36.5	A	140	180	63	342

競合価格とは完全競争市場において、需要と供給の関係によって決定される価格。均衡価格。

- データ分析の目的
- 回帰分析とは？
- 高校数学の復習
- 利用データ
- 順序と手順
- R言語によるデータ分析実践
- 回帰分析の発展

データ分析の主要な目的

4

- データ分析の主要な目的の一つ：「予測」
 - 例1: 売り上げ個数の予測
 - 例2: ダイレクトメールへの反応
 - 例3: Webでの登録率
- データ分析の二種類の予測
 - **予測したい変数（結果）**に**影響する要因（原因）**を想定し、モデルとして影響の仕方などをデータから推定
 - どんな原因が結果に影響しているかを検討可能。
 - データ分析の予測という言葉は**データを説明**するという意味も含む

何を何で予測するか？

5

- 分析の二つのポイント
 - 何を原因にするか？
 - **予測したい対象(結果)**を適切に説明するために、**どのような原因**が含まれるかを網羅的に考慮、選別が必要。
 - そのための重回帰分析は来週
 - 本日は単回帰分析
 - 予測すべき結果の重要性
 - 予測する結果には、予測すると意味のある結果を設定
 - 売り上げ個数を予測したいなら、売り上げ個数を素直に予測対象にすれば良いのか？

- あるスーパーで飲料Aの売り上げ予測を考えます。
- 次のように問題を設定
 - 飲料Aの売り上げ個数：予測変数 (結果) y
 - 統計学の用語では被説明変数または従属変数と呼ばれる
 - 予測変数 y に影響しそうなもの：原因 x
 - 統計学の用語では説明変数または独立変数と呼ばれる。
- モデルの構築：価格 x から 売り上げ個数 y を予測
 - 予測の方向性： $x \rightarrow y$ というように x から y を予測
 - モデルの意味：「価格からの影響は大きいだろうという仮説のもと」で、予測分析を試みる
 - 数式的表現 (モデル)： $y = f(x) = a \times x + b$
 - $y = f(x)$ は形式的な表現。
 - データ分析者が注視する部分は $a \times x + b$ の部分

- 価格を下げれば？
 - 直感的な解釈：売り上げ個数が増える
 - 記号の解釈： x の値が小さくなれば、 y の値が増える
- なぜ、価格を下げると売上個数が増えるのか？
 - 当たり前ではあるが、「安ければお客は買う」、「高ければお客は買わない」
- 思わぬ落とし穴が
 - この想定では、**価格の効果はあくまでも来店している顧客への効果**。従って、このお店の来店客数が一定でないならば、**結果変数に売上個数を設定するのは不適切**である
- 実は
 - 来店客100人当たりの商品の売り上げ個数 (売上個数 / 来店者数) の方が適切である。

- データ分析の目的
- **回帰分析とは？**
- 高校数学の復習
- 利用データ
- 順序と手順
- R言語によるデータ分析実践
- 回帰分析の発展

回帰分析とは？

9


- 回帰 = 予測
 - 回帰 (regression; リグレッション) とは
 - 直感的には
 - 目的となる結果の値を、他の原因を用いて予測すること
 - 統計的な用語的には
 - 「予測したい、または興味ある被説明変数 y の値」を、「他の説明変数 x 」を用いて予測すること
- 回帰関数とは？
 - 直感的には
 - 原因と考えられる要因を用いて予測された結果の値を、その要因の関数として $m(\text{原因変数})$ と書かれるもの
 - 統計的には
 - 説明変数 x を用いて予測された y の値を x の関数として $f(x)$ と書かれるもの

- 給料
 - 賃金を教育年数に回帰する
 - ある人が**大学に x 年勤めた**という事実 (説明変数) を手掛かりにして、**その人の賃金 y** (被説明変数)を予測すること
- モデル化
 - 記号化 $y = f(x) = a x + b$
 - 日本語対応 **その人の賃金** = $f(\text{大学に}x\text{年勤めた}) = \text{倍率} \times \text{大学に}x\text{年勤めた} + \text{切片}$
- 回帰係数 a
 - a は 回帰係数と呼ぶ
 - 回帰係数は何をするのか？
 - 賃金計算のために**大学に勤めた年数 x** に対して補正
 - 解釈) 年数にどれくらい影響されるかを回帰係数として表現

- 単回帰分析
 - 売上個数を予測するために次のようにモデル化
 - モデルの意味：「価格からの影響は大きいだろうという仮説のもと」で、予測分析を試みる
 - 一般化: **被説明変数 (結果)** = **回帰係数** × **説明変数 (原因)** + **切片**
 - 具体化: **売上個数** = **影響度** × **価格** + **切片**
 - 記号化 (回帰式) : $y = a \times x + b$
 -

- データ分析の目的
- 回帰分析とは？
- **高校数学の復習**
- 利用データ
- 順序と手順
- R言語によるデータ分析実践
- 回帰分析の発展

- 関数とは
 - 一方の数値（変数 x ）が決まると、もう一方の数値（変数 y ）も決まる対応関係のこと
- 関数のグラフ
 - その x と y の対応関係を表現
 - 下図のような一次関数ではグラフは直線



- a は傾き、 b は切片。この a と b の値を調節することで、直線グラフの、傾き具合や位置が変わります。
- この a と b は、補助的な変数で、パラメータといいます。

単回帰

- 1つの変数の値を、別の一つの変数の値の線形式から予測・説明するものは以下のような式で表現（統計の教科書では切片 b は e と表記されることがある）

$$y = f(x) = ax + e$$


重回帰

- 複数の変数に予測する場合は次のような式で表現
$$y = f(x) = a_1x_1 + a_2x_2 + \cdots + a_nx_n + e$$
- これらの式で目的変数を予測できるように、**係数 a の値（大きさや種類への重み）を調整しながら適切な重みを探す**

パラメータの調整


14

・ 係数 a の値（大きさや種類への重み）を調整しながら適切な重みを探すとは？



この式（線）では実際の敵の強さの表現不可能

・ 下記のようにデータがうまく直線上に乗るように直線の傾きを調整



直線とデータがよりうまく収まる

データに対してよく当て当てはまる線を引きたい
($y = a \times x + b$ を構築し、 a と b の値を知りたい)

- データ分析の目的
- 回帰分析とは？
- 高校数学の復習
- **利用データ**
- 順序と手順
- R言語によるデータ分析実践
- 回帰分析の発展

- データの中身

- 2ヶ月分のある商品Aの売上データを、売上個数、来店客数、価格、競合の価格、最高気温、陳列方法の6個の原因を集計

- 表: 2ヶ月分のある商品Aの売上データ

no	最高気温	陳列方法	価格	競合価格	売上個数	来店客数
1	27.8	B	160	168	82	579
2	27.8	A	160	168	57	602
3	28.4	A	175	180	46	501
...	.	.	.	.	.	.
61	36.5	A	140	180	63	342

- データ分析の目的
- 回帰分析とは？
- 高校数学の復習
- 利用データ
- **順序と手順**
- R言語によるデータ分析実践
- 回帰分析の発展

- 順序1
 - 価格から来店客数100人あたりの売り上げを予測する
- 順序2
 - p値の解釈
- 順序3
 - 説明力の確認

- 価格から来店客数100人あたりの売り上げを予測する
 - 手順 0 : データの読み込み
 - 手順 1 : データの確認
 - 手順 2 : データの整形
 - 手順 3 : データのプロットによる全体像の把握
 - 手順 4 : モデルの構築と係数を求める
 - 手順 5 : 結果を解釈する

- データ分析の目的
- 回帰分析とは？
- 高校数学の復習
- 利用データ
- 順序と手順
- **R言語によるデータ分析実践**
- 回帰分析の発展

データの読み込みと確認

21

- 必要なデータを読み込む
 - 配布した「07data.csv」を指定
 - データを読み込んだら、保存のために変数に代入。

```
import pandas as pd
sales_data = pd.read_csv("data/07data.csv", encoding="shift_jis")
```

- 基本事項の確認
 - データの中身が正しいかを確認。

```
1 display(sales_data)
```

✓ 0.0s

	no	最高気温	陳列方法	価格	競合価格	売上個数	来店客数
0	1	27.8	B	160	168	82	579
1	2	27.8	A	160	168	57	602
2	3	28.4	A	175	180	46	501
3	4	27.8	A	175	180	40	434
4	5	28.5	B	140	180	75	379
...	...	...	...	...	...	...	...

```
1 sales_data.describe()
```

✓ 0.0s

	no	最高気温	価格	競合価格	売上個数	来店客数
count	61.000000	61.000000	61.000000	61.000000	61.000000	61.000000
mean	31.000000	30.821311	160.819672	172.606557	62.524590	493.868852
std	17.752934	2.627934	14.496561	10.085102	25.796386	111.893175
min	1.000000	27.200000	140.000000	145.000000	14.000000	298.000000
25%	16.000000	28.400000	140.000000	168.000000	42.000000	411.000000
50%	31.000000	30.500000	160.000000	180.000000	62.000000	480.000000
75%	46.000000	33.300000	175.000000	180.000000	77.000000	590.000000
max	61.000000	36.500000	175.000000	180.000000	121.000000	711.000000

- 出力される内容（数値列）：

- count（件数）
- mean（平均）
- std（標準偏差）
- min（最小値）
- 25%（第1四分位）
- 50%（中央値）
- 75%（第3四分位）
- max（最大値）

- 単回帰分析
 - Step 1
 - 価格から売上個数を予測
 - 仮説：「売上個数は価格に大きく影響される」
 - 一般化: **被説明変数 (結果)** = 回帰係数 × 説明変数 (原因) + 切片
 - 具体化: **売上個数** = 影響度 × 価格 + 切片
 - 記号化 (回帰式) : $y = a \times x + b$
- sm.OLS関数を利用した単回帰分析
 - import statsmodels.api as sm を利用する
 - sm.OLS(y, X).fit() のように実行する

データの結合と列名

24

- 「価格から来店客数100人あたりの売上個数を予測する」を実現するために、次のようにプログラムする

```
1 # 一人あたりの個数を計算
2 sales_data["一人あたり"] = sales_data["売上個数"] / sales_data["来店客数"]
3 # 百人あたりの個数を追加
4 sales_data["百人あたり個数"] = sales_data["一人あたり"] * 100
```


データの確認

25

- 一人あたりと百人あたり個数の列名が追加されている

```
1 display(sales_data)
```

✓ 0.0s Python

	no	最高気温	陳列方法	価格	競合価格	売上個数	来店客数	一人あたり	百人あたり個数
0	1	27.8	B	160	168	82	579	0.141623	14.162349
1	2	27.8	A	160	168	57	602	0.094684	9.468439
2	3	28.4	A	175	180	46	501	0.091816	9.181637
3	4	27.8	A	175	180	40	434	0.092166	9.216590
4	5	28.5	B	140	180	75	379	0.197889	19.788918
...	...	...	...	...	...	...	...	...	...

- 一人あたりの個数の平均と100人あたりの個数の平均は

```
2 sales_data["一人あたり"].mean()
```

✓ 0.0s

0.1266584034716343

```
1 sales_data["百人あたり個数"].mean()
```

✓ 0.0s

12.665840347163428

データの全体像

26


- plot関数を用いてデータの全体像を確認する

```
1 # 散布図を描画
2 import matplotlib.pyplot as plt
3 plt.scatter(sales_data["価格"], sales_data["百人あたり個数"])
4 plt.xlabel("Price")
5 plt.ylabel("Per 100 customers")
```

✓ 0.2s

Python

Text(0, 0.5, 'Per 100 customers')



140円から175円までのデータであることを確認

全体像の概要

27

```
1 sales_data.describe()
```



0.0s

Python

	no	最高気温	価格	競合価格	売上個数	来店客数	一人当たり
count	61.000000	61.000000	61.000000	61.000000	61.000000	61.000000	61.000000
mean	31.000000	30.821311	160.819672	172.606557	62.524590	493.868852	0.126658
std	17.752934	2.627934	14.496561	10.085102	25.796386	111.893175	0.045492
min	1.000000	27.200000	140.000000	145.000000	14.000000	298.000000	0.032407
25%	16.000000	28.400000	140.000000	168.000000	42.000000	411.000000	0.094675
50%	31.000000	30.500000	160.000000	180.000000	62.000000	480.000000	0.127711
75%	46.000000	33.300000	175.000000	180.000000	77.000000	590.000000	0.164474
max	61.000000	36.500000	175.000000	180.000000	121.000000	711.000000	0.218018

- 単回帰分析
 - Step 1
 - 価格から売上個数を予測
 - 仮説：「売上個数は価格に大きく影響される」
 - 一般化: 被説明変数 (結果) = 回帰係数 × 説明変数 (原因) + 切片
 - 具体化: 売上個数 = 影響度 × 価格 + 切片
 - 記号化 (回帰式) : $y = a \times x + b$

```
1 # 回帰分析
2 import statsmodels.api as sm
3 X = sales_data["価格"]
4 X = sm.add_constant(X) # 定数項を追加
5 y = sales_data["百人あたり個数"]
6 model = sm.OLS(y, X).fit() # OLS回帰モデルの適合
7 print(model.summary())
```

分析結果の表示

29

OLS Regression Results

```
=====
Dep. Variable:                百人あたり個数    R-squared:                0.583
Model:                        OLS              Adj. R-squared:           0.576
Method:                        Least Squares    F-statistic:              82.46
Date:                          Sun, 25 May 2025  Prob (F-statistic):      8.38e-13
Time:                          18:33:55        Log-Likelihood:           -151.79
No. Observations:              61              AIC:                      307.6
Df Residuals:                  59              BIC:                      311.8
Df Model:
```

```
Covariance Type:
=====
```

回帰式 $y = (-0.23959) \times x + 51.19668$ を求められた

	coef	std err	t	P> t	[0.025	0.975]
const	51.1967	4.260	12.018	0.000	42.672	59.721
価格	-0.2396	0.026	-9.081	0.000	-0.292	-0.187

```
=====
Omnibus:                      4.538          Durbin-Watson:           2.053
Prob(Omnibus):                 0.103          Jarque-Bera (JB):        2.305
Skew:                          -0.192         Prob(JB):                0.316
Kurtosis:                     2.129          Cond. No.                1.81e+03
```


- $y = (-0.23959) \times x + 51.19668$ の二つの解釈方法
 - マーケティング施策の影響の大きさの検討が可能
 - 価格の回帰係数が -0.23959 である
 - (意識) 1 円 の値上げは、来店客数百人あたり 約0.24個 減らす影響がある
 - 回帰係数の利用方法：(例). 価格 20 円上げた時の影響を知る
 - $-0.23959 \times \text{価格 } 20 \text{ 円} = \underline{-4.7918}$
 - (意識) 価格の回帰係数 $\times$ 価格 とすることで、来店客数百人あたり約4.8個減少すると予測可能。
 - 値付けをした際の予測が可能
 - (例) ある商品に 150 円の値段をつけた
 - 回帰式を利用 $(-0.23959) \times 150 + 51.19668 = 15.25818$
 - (意識) 1 日に来店人数数百人あたり約15.3 個売れる

- 回帰式の価格に 50 円を設定してはいけない
 - 回帰分析に利用したデータは、140 円から 175 円である
 - このデータの確認をするために Summary 関数を用いた
- そのため、50円というデータからあまりにも離れたデータを利用しても、予測から大きく外れる可能性がある。
 - なぜだろうか？ 極端な話, 1円の商品と150円の商品の売れ行き方を想像してみよう。1円の商品は150円の商品の売れ行きとは全く異なる。
 - (意訳) 想定している価格帯 50円は、消費者の価格感度が異なる。
 - 統計的な意味: モデルの傾き (a) が異なる

- 誤判断のリスク検討: p値から仮説検証
 - p値とは？
 - (復習) p 値は有意確率
 - 回帰分析では原因変数の評価に用いられる
 - どこを見ればいいのか？
 - $\Pr(>|t|)$ の $8.38e-13$
 - e- の表記は 8 の前に 0 が 13個つ0.000000000000000838を意味する
 - $8.38e-13$ の意味は？
 - この価格（原因）が百人あたりの個数（結果）に影響を与えているといったときに、それが誤りである確率
 - p値は原因が影響するかどうかの客観的な指標になることがある
 - p値は 0 から 1 の値を取り、0 に近いほど、その原因から影響があると言いやすくなる。

- p値が0.8の例
 - 誤解例
 - p値は、原因 x が結果 y に影響しない確率ではない
 - 例えば、影響しない確率が 80 % という
 - 正解例
 - このデータから、価格が百人あたりの個数に影響する、という主張が **たまたま影響があるという結果になっている** 確率が80 % という **消極的な主張** しかできない。
- つまりどういうこと？
 - p値は、たまたまそうなた確率
 - だから、断言しては理論的な矛盾になる


- 回帰直線を引き、どれほど説明できているかを確認

```
1 plt.scatter(sales_data["価格"], sales_data["百人あたり個数"], label="Data")
2
3 # 回帰直線
4 pred_y = model.predict(X)
5 plt.plot(sales_data["価格"], pred_y, color="red", label="Regression line")
6
7 # 軸ラベルと凡例
8 plt.xlabel("Price")
9 plt.ylabel("Per 100 customers")
10 plt.legend()
11
```

✓ 0.2s

Python

<matplotlib.legend.Legend at 0x141973140>



実際のデータを説明しきれていない

- 回帰直線を描き、データからどのくらい離れているかを視覚的に確認した。
 - 統計的な用語では 実測値 - 推定数値を誤差としたとき、その誤差が大きいこと確認した。
 - 本来はこの誤差を利用して**最小二乗法**を行うが省略
 - 客観的な数値で、このズレを確認したいとき
 - 0 から 1 の範囲を取る決定係数 R^2 を利用
 - 1 の場合、実測値と予測が完全に一致
 - 0 の場合、実測値と予測が完全に不一致
- R-squared: 0.583
- 価格では百人あたりの個数の動きでは 58.3%は説明できる

そのほかにも影響する原因を考えなくてはならない

- 決定係数は 1 でなければならない？
 - 実は、「決定係数は 0.9 以上でないという意味のないモデル」と時々教えられることがあります。
 - 確かに、決定係数が 1 に近いほど良いモデルであることは間違いありません。
 - ただし、実は何%以上の説明力がないと利用できない、ということはない
- 回帰分析の重要な点は
 - 説明変数（原因）と被説明変数（結果）の関係を数式化（モデル化）することが最も重要な点
 - つまり、原因と結果の構造を確認したい。
 - このモデル化を通して、変数間の関係や予測を行うことができる。

- データ分析の目的
- 回帰分析とは？
- 高校数学の復習
- 利用データ
- 順序と手順
- R言語によるデータ分析実践
- 回帰分析の発展

- RMSEとは
 - Root Mean Squared Error : 平方平均二乗誤差といい、実測値(x) - 予測値 $m(x)$ = 誤差を二乗し、平均を求めて、ルートをとった値。つまり、予測誤差の平均

```
1 import numpy as np
2 # 残差 (実測値 - 予測値)
3 residuals = y - model.predict(X)
4 # RMSE の計算
5 rmse = np.sqrt(np.mean(residuals ** 2))
6 print("RMSE:", rmse)
```

[23] ✓ 0.0s

... RMSE: 2.9137488905224176

当たり前から脱却する

39

- 回帰分析では、時折、当たり前の結果が得られる
 - これは、回帰分析を予測できることのみに使うために、それだけしか得られない
- 回帰分析の外れた方に着目する
 - 日毎の売り上げ個数の推定誤差がRMSEの何個分ずれているかを計算すると、どの日が大きくずれているのかがわかる。

```
1 pd.set_option("display.max_rows", 1000)
2 print(residuals / rmse)
```

✓ 0.0s

0	0.446203
1	-1.164749
2	-0.029767
3	-0.017771
4	0.732694
5	0.036902
6	1.813692
7	-0.503049

ズレが1.81個と大きいため七日目に着目
実測値(14.55)と予測値(9.268)を求めると、
予測よりも 5.28多く売れていることがわかる。
予測の外れ方の平均(RMSE)2.91の1.8倍外れている。

なぜこんな複雑なことを？ 例えば、175円で売っているので来店客百人あたり、9.27個予測なのに、実際は14.6個も大きく売り上げが伸びた。では、売上に貢献した要因はなんだろうか？ もしかしたら陳列方法がAだったのかもしれない。それらを原因として追加すれば、もっと予測がうまく行くだろうと考えられる。

- 原因に質的変数を利用する
 - これまでの分析では、量的変数を利用した
- 陳列方法は売上個数に影響するかを検証
 - 陳列方法Aと陳列方法Bの両方の影響をそれぞれ分析する
- 注意
 - 陳列方法Aは 0 , 陳列方法Bは1 と変換するタミー変数化が必要
 - `pd.get_dummies`


```
1 # ダミー変数化 (Aを0, Bを1とする)
2 X = pd.get_dummies(sales_data["陳列方法"], drop_first=True)
3 X = sm.add_constant(X).astype(float)
4 # 目的変数
5 y = sales_data["売上個数"]
6 # 回帰
7 model = sm.OLS(y, X).fit()
8 print(model.summary())
```

✓ 0.0s

Python

OLS Regression Results

```
=====
Dep. Variable:          売上個数    R-squared:            0.235
Model:                  OLS        Adj. R-squared:        0.222
Method:                 Least Squares    F-statistic:      18.16
Date:                   Sun, 25 May 2025    Prob (F-statistic): 7.41e-05
Time:                   19:09:16    Log-Likelihood:    -276.13
No. Observations:       61    AIC:                   556.3
Df Residuals:           59    BIC:                   560.5
Df Model:                1
Covariance Type:        nonrobust
=====
```

	coef	std err	t	P> t	[0.025	0.975]
const	51.0909	3.960	12.902	0.000	43.167	59.014
B	24.9091	5.845	4.262	0.000	13.214	36.604

- 陳列方法Aの場合の売上予測
 - $51.1 + 24.9 \times 0 = 51.1$
 - 注意：陳列方法Aは 0 であるため
- 陳列方法Bの場合の売上予想
 - $51.1 + 24.9 \times 1 = 76.0$
 - 注意：陳列方法Bは1であるため
- ダミー変数による質的変数の採用により、結果へその係数をたすかどうかが変わる
- そのため、陳列方法BはAよりも平均24.9個多く売れていることがわかる。

p値の実務的な活用術

43

- これまでの想定
 - 価格が百人あたりの個数に影響を与える (p値は $8.38e-13$)
- 別の想定
 - その日の最高気温が商品の百人あたりの個数に影響を与える

```
1 # 回帰分析
2 import statsmodels.api as sm
3 X = sales_data["最高気温"]
4 X = sm.add_constant(X) # 定数項を追加
5 y = sales_data["百人あたり個数"]
6 model = sm.OLS(y, X).fit() # OLS回帰モデルの適合
7 print(model.summary())
```

✓ 0.0s

OLS Regression Results

Dep. Variable:	百人あたり個数	R-squared:	0.010
Model:	OLS	Adj. R-squared:	-0.007
Method:	Least Squares	F-statistic:	0.5690
Date:	Sun, 25 May 2025	Prob (F-statistic):	0.454
Time:	19:12:05	Log-Likelihood:	-178.17
No. Observations:	61	AIC:	360.3
Df Residuals:	59	BIC:	364.6
Df Model:	1		
Covariance Type:	nonrobust		

	coef	std err	t	P> t	[0.025	0.975]
const	7.4511	6.938	1.074	0.287	-6.431	21.333
最高気温	0.1692	0.224	0.754	0.454	-0.280	0.618

- このデータから最高気温が百人あたりの個数に影響を与えていると結論づけられるだろうか？
- 最高気温は影響しているとは言い切れない。

- 基本統計量を用いて、2ヶ月分のある商品Aの売上データを説明しなさい（100字から200字程度）
- ヒストグラムを用いて、売上個数と100人あたりの売上個数を説明しなさい（100字から200字程度）

- 以下の仮説に対して、lm関数を用いた回帰分析を実施した結果をレポートしなさい。
 - 仮説1 「来店客数100人あたりの売上個数は価格に大きく影響」
 - lm関数の結果を示しなさい。
 - lm関数の結果から回帰式を具体的に求めなさい。
 - 上記の回帰式を被説明変数や、説明変数、切片、などの用語を利用して、具体的に説明しなさい（200字程度）。
 - lm関数の結果にある内容を、回帰係数、切片、回帰式、p値などの用語を利用して具体的に説明しなさい。

- 30枚目の結果の解釈1を参考に、得られた回帰式の解釈を説明しなさい。
- 34枚目の説明力の確認のスライドを参考に、グラフを描きなさい。どの程度当てはまりが良かったのか感想で良いので思うことを答えなさい。

- 以下の仮説に関しても、通常課題1の通りにレポートしなさい。
 - 仮説2 「来店客数100人あたりの売上個数は陳列方法に大きく影響」
 - 仮説3 「来店客数100人あたりの売上個数は最高気温に大きく影響」

- これまで求めた、最高気温、陳列方法、価格の各数値から、どの説明変数が百人あたりの個数にもっとも影響するのか示し、その理由を考察しなさい（200字から400字）。

